¹Universidad Sergio Arboleda **Presentado por** Guillermo De Mendoza Nataly Jineth Roa Peña

Análisis de datos a partir de información encontrada para cada base de datos


Análisis de datos para 11 tablas con 11 países de latinoamérica, el objetivo principal de este análisis es reconocer y eliminar NaN.

```
df.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10259 entries, 0 to 10258
Data columns (total 72 columns):
    Column
                                                   Non-Null Count Dtype
     -----
- - -
                                                   -----
 0
    Unnamed: 0
                                                   10259 non-null int64
    Organization Name
 1
                                                   10259 non-null object
    Organization Name URL
 2
                                                   10259 non-null object
                                                   10127 non-null object
 3
    Industries
 4
    Headquarters Location
                                                   10259 non-null object
 5
    Description
                                                   10259 non-null object
    CB Rank (Company)
                                                   10259 non-null object
 6
 7
    Headquarters Regions
                                                   8259 non-null
                                                                   object
 8
    Estimated Revenue Range
                                                   6124 non-null
                                                                   object
 9
    Operating Status
                                                   10259 non-null object
 10 Founded Date
                                                   9897 non-null
                                                                   object
    Founded Date Precision
                                                   9897 non-null
                                                                   object
 11
 12 Exit Date
                                                   1300 non-null
                                                                   object
 13 Exit Date Precision
                                                   1300 non-null
                                                                   object
                                                   10033 non-null object
 14 Company Type
 15 Website
                                                   10180 non-null object
 16 Twitter
                                                   7386 non-null
                                                                   object
 17 Facebook
                                                   7494 non-null
                                                                   object
 18 LinkedIn
                                                   8440 non-null
                                                                   object
 19 Contact Email
                                                   8324 non-null
                                                                   object
```

_


¹ Bitacora-Mineria de datos


```
20 Phone Number
                                                              6451 non-null object
21 Number of Articles
                                                              5782 non-null object
                                                                                  object
22 Hub Tags
                                                              433 non-null
                                                              9012 non-null
23 Full Description
                                                                                  object
                                                              10127 non-null object
24 Industry Groups
25 Number of Founders
                                                              7528 non-null float64
26 Founders
                                                              7528 non-null object
27 Number of Employees
                                                              9871 non-null object
28 Number of Funding Rounds
                                                              7860 non-null float64
29 Funding Status
                                                              6663 non-null object
30 Last Funding Date
                                                              7860 non-null object
31 Last Funding Amount
                                                              6647 non-null float64
32 Last Funding Amount Currency
                                                              6650 non-null object
33 Last Funding Amount Currency (in USD)
                                                          6647 non-null float64
34 Last Funding Type
                                                             7860 non-null object
35 Last Equity Funding Amount
                                                            6351 non-null float64
                                                              6354 non-null object
36 Last Equity Funding Amount Currency
37 Last Equity Funding Amount Currency (in USD) 6351 non-null float64
38 Last Equity Funding Type
                                                             7451 non-null object
                                                              6957 non-null float64
39 Total Equity Funding Amount
40 Total Equity Funding Amount Currency
                                                              6957 non-null object
41 Total Equity Funding Amount Currency (in USD) 6957 non-null float64
42 Total Funding Amount
                                                              7400 non-null float64
                                                              7400 non-null object
43 Total Funding Amount Currency
                                                              7400 non-null float64
44 Total Funding Amount Currency (in USD)
45 Top 5 Investors
                                                              6861 non-null object
46 Number of Lead Investors
                                                              4954 non-null float64
47 Number of Investors
                                                              6868 non-null float64
48 Number of Acquisitions
                                                              1032 non-null
                                                                                 float64
49 Acquisition Status
                                                              1663 non-null
                                                                                 object
50 IPO Status
                                                              10259 non-null object
 51 IPO Date
                                                       567 non-null
                                                                          object
 52 Stock Symbol
                                                       566 non-null
                                                                         object
 53 Stock Symbol URL
                                                       567 non-null object
 54 Stock Exchange
                                                      565 non-null object
                                                     355 non-null object
2297 non-null float64
10259 non-null object
9919 non-null float64
 55 Last Leadership Hiring Date
 56 Number of Events
57 CB Rank (Organization)
58 BuiltWith - Active Tech Count
59 Apptopia - Number of Apps
60 Apptopia - Downloads Last 30 Days
61 G2 Stack - Total Products Active
62 IPqwery - Patents Granted
63 IPqwery - Trademarks Registered
64 IPqwery - Most Popular Patent Class
65 IPqwery - Most Popular Trademark Class
66 Aberdeen - IT Spend
673 non-null object
68 Aberdeen - IT Spend
69199 non-null object
692 1004 non-null object
693 1004 non-null object
694 1007 non-null object
695 1007 non-null object
696 Aberdeen - IT Spend
697 non-null object
698 non-null object
 67 Aberdeen - IT Spend Currency
                                                       1145 non-null object
 68 Aberdeen - IT Spend Currency (in USD)
                                                       1098 non-null
                                                                         float64
 69 Ciudad
                                                       10259 non-null object
 70 Departamento
                                                       10000 non-null object
 71 Pais
                                                        10259 non-null object
dtypes: float64(19), int64(1), object(52)
memory usage: 5.6+ MB
```




Aquí encontramos información descriptiva de la unión de los data frame

• Información descriptiva de las variables





podemos denotar la distribución de Industries a demás



Función para detectar el porcentaje de NaN por cada columna para los 11 archivos. Entradas:

- datos, los data frame que se quieren analizar
- per nulls cuanto es lo mínimo de porcentaje que es tolerable para el análisis.

para el análisis de estos datos notamos que lo mínimo de consideración es el 50%, pero al nivel de levantamiento de los datos el negocio dejó claro que para ellos lo mínimo es el 70% de los NaN

¿Cual es la salida?

nos entrega un análisis por variable con la cantidad en valor del porcentaje del total de NaN.

	Arg	Bra	Chi	Col	Ger	Isr	Mex	Spa	Swi	Uru	Usa	
Estimated Revenue Range	0.543	NaN	0.621	0.603	NaN	NaN	0.604	NaN	NaN	0.559846	NaN	
Exit Date	0.900	0.912	0.940	0.938	0.832	0.810	0.906	0.894	0.880	0.930502	0.70	
Exit Date Precision	0.900	0.912	0.940	0.938	0.832	0.810	0.906	0.894	0.880	0.930502	0.70	
Closed Date	0.985	0.989	0.984	0.989	0.997	0.992	0.992	0.994	0.993	0.992278	0.99	
Closed Date Precision	0.971	0.980	0.965	0.978	0.996	0.991	0.980	0.988	0.992	0.984556	0.99	
Aberdeen - IT Spend Currency (in USD)	1.000	1.000	1.000	1.000	0.727	1.000	1.000	0.836	0.847	1.000000	NaN	
School Method	1.000	0.998	1.000	1.000	1.000	1.000	1.000	1.000	1.000	1.000000	1.00	
Number of Founders	NaN	NaN	NaN	0.564	NaN	NaN	NaN	NaN	NaN	0.621622	NaN	
Founders	NaN	NaN	NaN	0.564	NaN	NaN	NaN	NaN	NaN	0.621622	NaN	
Headquarters Regions	NaN	NaN	NaN	NaN	NaN	1.000	NaN	NaN	1.000	NaN	NaN	

Función para corregir espacios, que recibe:

• la palabra para borrar el espacio en blanco su salida, es una palabra sin espacios.

```
In [24]: #Funcion que corrige espacios
def correct_word(word):
    new_word = word.split()[0]
    return new_word
```

Esta función es creada con el fin de encontrar todos los nombres relacionados con LaTaM, y así poder realizar un filtro para hacer el análisis descriptivo que lo relacione, que recibe esta función:

- 1. df= data frame
- 2. col= el nombre de la variable donde se debe buscar la palabra


1. Cuánto capital se ha invertido en LaTAM durante el último año. Desagregue gráficamente por país.

Para iniciar a hacer este análisis necesitamos hacer un primer procesamiento de los datos para encontrar la información y el análisis adecuado.

```
def obtener palabras(df, col):
    lista palabras = []
    for word in df[col]:
        if 'LATAM' in word:
            lista palabras.append(word)
        else:
            continue
    return lista palabras
list latam = obtener palabras(df, 'Organization Name')
#df[df['Organization Name'] in list_latam]
list latam
['DTA LATAM',
 'OM LATAM',
 'LATAM BRASIL',
 'CUPONATIC LATAM',
 'LATAMLEAP',
 'LATAM AIRLINES GP',
 'GROUPON LATAM',
 'SCM LATAM',
 'IBR LATAM',
 'OMNI LATAM',
 'SOY STARTUP LATAM',
 'FRANQUICIAS LATAM',
 'MDALATAM UNIVERSITY',
 'INVEST LATAM']
```

De la función anterior encontramos todos los nombres que están relacionados con LaTaM.

Iniciamos el análisis de cuál es el país que más invierte en LaTaM y análisis descriptivo de cada variable.



2. Haga una comparación entre Colombia con cada uno de los otros países. Analice.

```
df ciudad=df.groupby(by='Pais')['Last Funding Amount Currency (in USD)'].sum()
df ciudad[:20].plot(kind='barh')
#plt.xscale('log')
<AxesSubplot:ylabel='Pais'>
    Uruguay
     United
  Switzerland
      Spain
     Mexico
      Israel
    Germany
   Colombia
      Chile
      Brazil
   Argentina
                             1.00
                                 1.25
         0.00
              0.25
                   0.50
                       0.75
                                      1.50
                                           1.75
                                                2.00
                                                1e11
Pais
Argentina
                   9.348042e+08
Brazil
                   1.456192e+10
Chile
                   2.437126e+09
Colombia
                   5.049966e+09
Germany
                   5.265208e+10
                   1.715243e+10
Israel
Mexico
                   1.245483e+10
Spain
                   2.050172e+10
Switzerland
                   1.259551e+10
United
                   1.952392e+11
Uruguay
                   4.873965e+08
Name: Last Funding Amount Currency (in USD), dtype: float64
```


Colombia y Chile están por la misma cantidad de inversión y son de los países con menor inversión.

Análisis descriptivo para para solucionar las preguntas del 3-6

Vamos a crear un filtro


	Unnamed: 0	Organization Name	Organization Name URL	Industries	Headquarters Location	Description	CB Rank (Company)	Headquarters Regions	Estimated Revenue Range	Operating Status	 IPqwery - Patents Granted	IP Trad Reg
6055	55	GOTRENDIER	https://www.crunchbase.com /organization/gotren	E-Commerce, Fashion, Internet	Colombia, Nuevo Leon, Mexico	GoTrendier is a fashionable community.	18,596	Latin America	NaN	Active	 NaN	
6234	234	PINBUS.COM	https://www.crunchbase.com /organization/pinbus	Online Portals, Service Industry, Transportation	Colombia, Nuevo Leon, Mexico	Pinbus.com provides an online service to purch	67,261	Latin America	Less than 1M	Active	 NaN	
6514	514	BODYTECH	https://www.crunchbase.com /organization/bodytech	Fitness, Health Care, Sports, Wellness	Colombia, Nuevo Leon, Mexico	The second- largest gym company in Latin America	148,726	Latin America	1M to 10M	Active	 NaN	

• Nombre de organizaciones que están en colombia



5. Muestre el crecimiento porcentual mensual de ingresos por inversión en Colombia en comparación con los demás países.


[117]: Text(0.5, 0, 'Last Funding Amount (USD)')



df['Pais'].value_counts(normalize=True)

```
Spain
                0.097475
Brazil
                0.097475
Chile
                0.097475
Switzerland
                0.097475
Colombia
                0.097475
Argentina
                0.097475
Israel
                0.097475
Mexico
                0.097475
Germany
                0.097475
United
                0.097475
Uruguay
                0.025246
Name: Pais, dtype: float64
```


4. Muestre gráficamente los exits de capital privado en Colombia por deal size.



6. ¿De acuerdo con los hallazgos, que le hace falta a Colombia para lograr más inversión?

Notamos que Colombia solo tiene inversión en IPO Status al nivel privado, la inversiones en otros campos, al nivel de latinoamérica vemos como Argentina tiene una historia de inversión muy alineada a las compañías y al nivel de tecnología.

cuando inicie el análisis me concentré en conocer cada variable de forma descriptiva, y ver cual era la que me daba mas informacion al nivel de la información, una que me llamó mucho la atención fue la variable de tipos de servicio, están generando gran impacto en cada país, tanto al nivel privado como publico, asi que mi conclusión es que colombia debe invertir en la transformación digital y todo lo que la rodea.



PUNTO 2.1

ETL: Procesamiento de extracción, transformación y carga de datos:

paso 0: lectura del set de datos

```
df = pd.read_csv('..\\resources\\ColombiaFlagTop100.csv')
```


paso 1: proceso de limpieza de las columnas de datos con un porcentaje de nulos superior al 90%

```
def percentajeOfEmptyFieldsNumericColumn(dataframe,columnName):
    return df[columnName].isnull().sum() / len(dataframe)

columnNames = []
columnEmptyPercentajes = []

for columnName in df.columns:
    emptyFields = percentajeOfEmptyFieldsNumericColumn(df,columnName)
    columnNames.append(columnName)
    columnEmptyPercentajes.append(emptyFields)

plt.barh(columnNames,columnEmptyPercentajes)
plt.grid()
plt.show()
```



```
LIMIT_EMPTY_PERCENTAJE = 0.9
deletedColumns = 0
for columnName in df.columns:
    emptyFields = percentajeOfEmptyFieldsNumericColumn(df,columnName)
    if emptyFields >= LIMIT_EMPTY_PERCENTAJE :
        del df[columnName]
        deletedColumns+=1
print("Deleted columns: %d, columns remaining: %d"%(deletedColumns,len(df.columns)))
Deleted columns: 54, columns remaining: 53
```

paso 2: Los campos de rangos de valores se dividen en dos columnas independientes, donde se tendrá el máximo y mínimo como valores numéricos

Campo: "Estimated Revenue Range"

```
def convertRangeValue(inputValue):
   value = inputValue.strip()
    if(value=="$1M"):
        return 1000000
    elif(value=="$10M"):
        return 10000000
    elif(value=="$50M"):
        return 50000000
    elif(value=="$100M"):
        return 100000000
    elif(value=="$500M"):
        return 500000000
    elif(value=="$1B"):
        return 1000000000
    elif(value=="$10B"):
        return 10000000000
    else:
        print("OTRO",inputValue)
```

```
columnName = "Estimated Revenue Range"
#Estimated Revenue Range
df["minEstimatedRevenueRange"] = np.zeros(df.shape[0])
df["maxEstimatedRevenueRange"] = np.zeros(df.shape[0])
for index in range(len(df)):
   content = df.iloc[index][columnName]
   if pd.isnull(df.iloc[index][columnName]):
        df.iloc[index, df.columns.get_loc('minEstimatedRevenueRange')] = 0
        df.iloc[index, df.columns.get_loc('maxEstimatedRevenueRange')] = 0
        continue
   if(content=="Less than $1M"):
        minValue = 0
        maxValue = 1000000
   else:
        contentSplitted = content.split("to")
        minValue = convertRangeValue(contentSplitted[0])
        maxValue = convertRangeValue(contentSplitted[1])
    df.iloc[index, df.columns.get loc('minEstimatedRevenueRange')] = minValue
    df.iloc[index, df.columns.get loc('maxEstimatedRevenueRange')] = maxValue
del df[columnName]
```

Campo: "Number of Employees"

```
columnName = "Number of Employees"
#Estimated Revenue Range
df["minNumberEmployees"] = np.zeros(df.shape[0])
df["maxNumberEmployees"] = np.zeros(df.shape[0])
for index in range(len(df)):
    content = df.iloc[index][columnName]
    if pd.isnull(df.iloc[index][columnName]):
         df.iloc[index, df.columns.get_loc('minNumberEmployees')] = 0
df.iloc[index, df.columns.get_loc('maxNumberEmployees')] = 0
         continue
    if(content=="01-Oct"):
         df.iloc[index, df.columns.get loc('minNumberEmployees')] = 1000
         df.iloc[index, df.columns.get_loc('maxNumberEmployees')] = 2000
    if(content=="Nov-50"):
         df.iloc[index, df.columns.get_loc('minNumberEmployees')] = 2000
         df.iloc[index, df.columns.get_loc('maxNumberEmployees')] = 5000
         continue
    if(content=="10001+"):
         df.iloc[index, df.columns.get_loc('minNumberEmployees')] = 10000
         df.iloc[index, df.columns.get_loc('maxNumberEmployees')] = 99999
         continue
    contentSplitted = content.split("-")
    minValue = int(contentSplitted[0].strip())
    maxValue = int(contentSplitted[1].strip())
    df.iloc[index, df.columns.get_loc('minNumberEmployees')] = minValue
df.iloc[index, df.columns.get_loc('maxNumberEmployees')] = maxValue
del df[columnName]
```

Paso 3: Se refactoriza campos de contención de atributos booleanos que felicitan su procesamiento, al indicar si son o no son de un tipo específico, y si estos tienen o no un valor.

```
df["isCompanyTypeForProfit"] = np.zeros(df.shape[0])
df["Company Type"] = df["Company Type"].fillna("")
for index in range(len(df)):
    content = df.iloc[index]["Company Type"]
    if(content=="For Profit"):
        df.iloc[index, df.columns.get loc("isCompanyTypeForProfit")] = 1
df["isCompanyPrivate"] = np.zeros(df.shape[0])
df["IPO Status"] = df["IPO Status"].fillna("
for index in range(len(df)):
    content = df.iloc[index]["IPO Status"]
    if(content=="Private"):
        df.iloc[index, df.columns.get_loc("isCompanyPrivate")] = 1
df["hasWebsite"] = np.zeros(df.shape[0])
df["Website"] = df["Website"].fillna("")
for index in range(len(df)):
   content = df.iloc[index]["Website"]
    if(content!=""):
        df.iloc[index, df.columns.get loc("hasWebsite")] = 1
df["hasTwitter"] = np.zeros(df.shape[0])
df["Twitter"] = df["Twitter"].fillna("")
for index in range(len(df)):
    content = df.iloc[index]["Twitter"]
   if(content!=""):
        df.iloc[index, df.columns.get_loc("hasTwitter")] = 1
```

```
df["hasLinkedIn"] = np.zeros(df.shape[0])
df["LinkedIn"] = df["LinkedIn"].fillna("")
for index in range(len(df)):
   content = df.iloc[index]["LinkedIn"]
   if(content!=""):
        df.iloc[index, df.columns.get_loc("hasLinkedIn")] = 1
df["hasContactEmail"] = np.zeros(df.shape[0])
df["Contact Email"] = df["Contact Email"].fillna("")
for index in range(len(df)):
   content = df.iloc[index]["Contact Email"]
   if(content!=""):
        df.iloc[index, df.columns.get loc("hasContactEmail")] = 1
df["hasPhoneNumber"] = np.zeros(df.shape[0])
df["Phone Number"] = df["Phone Number"].fillna("")
for index in range(len(df)):
   content = df.iloc[index]["Phone Number"]
   if(content!=""):
        df.iloc[index, df.columns.get loc("hasPhoneNumber")] = 1
```

```
del df["Company Type"]
del df["Website"]
del df["Twitter"]
del df["Facebook"]
del df["LinkedIn"]
del df["Contact Email"]
del df["Phone Number"]
del df["IPO Status"]
```

Paso 4: Se reemplazan columnas de campos numericos con tontenidos nulos, y se llenan con zeros "0"

```
numericColumnsNames = [
   "CB Rank (Company)",
    "Number of Articles",
    "Number of Founders",
   "Number of Funding Rounds",
   "Last Funding Amount",
   "Last Funding Amount Currency (in USD)",
   "Last Equity Funding Amount",
   "Last Equity Funding Amount Currency (in USD)",
   "Total Equity Funding Amount",
   "Total Equity Funding Amount Currency (in USD)",
   "Total Funding Amount",
   "Total Funding Amount Currency (in USD)",
   "Number of Lead Investors",
   "Number of Investors",
   "Number of Events",
   "CB Rank (Organization)",
   "BuiltWith - Active Tech Count",
   "G2 Stack - Total Products Active"
for columnName in numericColumnsNames:
    df[columnName] = df[columnName].fillna(0)
```

Paso 5: Convertir valores flotantes en formato de comas "," a punto flotante

```
for index in range(len(df)):
    content = df.iloc[index]["CB Rank (Company)"]
    contentSplitted = content.split(",")
    buildedStringNumber = contentSplitted[0] + "." + contentSplitted[1]
    df.iloc[index, df.columns.get_loc("CB Rank (Company)")] = float(buildedStringNumber)

for index in range(len(df)):
    content = df.iloc[index]["CB Rank (Organization)"]
    contentSplitted = content.split(",")
    buildedStringNumber = contentSplitted[0] + "." + contentSplitted[1]
    df.iloc[index, df.columns.get_loc("CB Rank (Organization)")] = float(buildedStringNumber)
```

Paso 6: Carga de datos en un archivo CSV, el cual se guardará en la carpeta local del repositorio GIT

```
df.to_csv('ETL-out.csv')
```

PUNTO 2.2

Se realiza un análisis de componentes principales, con el fin de identificar la viabilidad en la segmentación entre los grupos de empresas, si esta se encuentra en el top 100 o no, mediante las entradas de valores de las variables del set de datos.

Paso 1: Cargar librerías

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA
from sklearn.preprocessing import StandardScaler
```

Paso 2: Dividir el set de datos en dos data frames independientes, teniendo en mente los valores que intentarán predecir si un input está en el top 100 o no lo esta

```
columns_X = [
    "CB Rank (Company)",
    "Number of Articles",
    "Number of Founders",
    "Number of Funding Rounds",
    "Last Funding Amount Currency (in USD)",
    "Last Equity Funding Amount Currency (in USD)",
    "Total Equity Funding Amount Currency (in USD)",
    "Total Funding Amount Currency (in USD)",
    "Number of Lead Investors",
    "Number of Investors",
    "Number of Events",
    "BuiltWith - Active Tech Count",
    "G2 Stack - Total Products Active",
    "minEstimatedRevenueRange",
    "maxEstimatedRevenueRange",
    "minNumberEmployees",
    "maxNumberEmployees"
    "isCompanyTypeForProfit",
    "isCompanyPrivate",
    "hasWebsite",
    "hasTwitter'
    "hasTwitter",
"hasFacebook",
    "hasLinkedIn",
    "hasContactEmail",
    "hasPhoneNumber",
    "isOperating"
]
X = pd.read_csv('.\\ETL-out.csv')
for column in X.columns:
   if (not column in columns_X ):
        del X[column]
```

```
columns_y = ["isInTop100"]

y = pd.read_csv('.\\ETL-out.csv')
for column in y.columns:
   if (not column in columns_y ):
        del y[column]
```

Paso 3: Normalización de los datos

```
In [7]: X_std = StandardScaler().fit_transform(X)
print('NumPy covariance matrix: \n%s' %np.cov(X_std.T))
              NumPy covariance matrix:
              [[ 1.00438596e+00 -2.11156754e-01 -1.43730342e-01 -3.32805283e-01 -8.02292062e-02 -8.22356536e-02 -9.65216552e-02 -1.03842498e-01 -3.56678802e-01 -2.78995262e-01 -1.14998906e-01 -4.02030028e-01
                 -1.62577893e-02 -7.78712116e-02 -6.93291065e-02 -1.06416093e-01 -8.02612925e-02 7.55587646e-02 4.46427110e-03 -3.16944405e-01
                  8.72646526e-02 -1.06679724e-01 -4.51783278e-01 -1.49436247e-01
                   3.64969443e-02 -2.75104043e-01]
               [-2.11156754e-01 1.00438596e+00 1.53488870e-01 4.02691551e-01
                  4.45435834e-01
5.94477664e-01
                                            2.27045931e-01 6.63445049e-01 7.44253285e-01 5.83520626e-01 2.41758771e-01 2.00728330e-01
                   3.31240551e-01 -2.06304928e-04 -2.10462872e-02 3.06203921e-01 2.74240177e-01 2.77653056e-02 -1.84637271e-01 5.53590647e-02
                   8.47168752e-02
                                            8.11627232e-02 1.59254627e-01 7.56520474e-02
                                            7.64099972e-02]
1.53488870e-01 1.00438596e+00 3.19939333e-01
                   1.03684613e-01
               [-1.43730342e-01
                  1.3568184e-01 -9.27451780e-02 -2.45826873e-03 -6.84368526e-02 1.9986354e-01 -2.25113257e-01 2.07895829e-02 8.75087955e-02 1.05601788e-01 -4.14159466e-02 -7.73287015e-02 -6.27403460e-02
                   8.02990417e-02 1.51365663e-01 1.03843118e-01 5.76233436e-02
```

Paso 4: Calcular los autovectores y autovalores

```
In [8]: cov_mat = np.cov(X_std.T)
               eig vals, eig vecs = np.linalg.eig(cov mat)
              print('Eigenvectors \n%s' %eig_vecs)
print('\nEigenvalues \n%s' %eig vals)
               Eigenvectors [[-1.75359657e-01 -2.22497369e-01 -1.55346717e-01 1.67807117e-01
                   3.45530708e-01 -6.82032912e-02 -1.71510046e-03
4.99627238e-02 3.09313877e-02 -2.36229711e-01
                                                                                                       4.31490068e-03
3.46136650e-02
                  -8.27202558e-02 -2.01113353e-01 -1.65538884e-01 -5.62846988e-02 -9.57596533e-02 -3.82551831e-01 -5.76098513e-02 4.98794505e-02 -5.02716300e-01 -2.04614601e-01 -1.54525256e-01 2.90765376e-01
                1.94787146e-01
[ 3.73857895e-01
                                               5.28523501e-02]
5.51072829e-02 -1.13041137e-01 3.51970160e-02
                    7.76206125e-02
1.71508161e-01
                                               1.42462161e-01 -5.87004664e-03 -8.11026756e-02 5.33442839e-01 -8.41627309e-02 -3.62546293e-02
                                              -1.47760857e-01
                    3.29660458e-01
                   -2.53851116e-01
                -2.53851116e-01 -2.10330154e-01 -1.605/093/e-01 9.65553/1e-02 -9.47216435e-02 -9.31152794e-02]
[5.56929732e-02 2.78045063e-01 5.08915621e-02 -1.23398566e-02 2.70984312e-01 1.14177943e-01 -4.25656523e-03 -2.82634247e-02 1.78805641e-01 3.00924260e-02 2.32844152e-01 1.81356874e-01
                    -4.98122375e-02 5.23451101e-02 -5.12921901e-01 4.39474384e-01
```

```
# Hacemos una lista de parejas (autovector, autovalor)
eig_pairs = [(np.abs(eig_vals[i]), eig_vecs[:,i]) for i in range(len(eig_vals))]
# Ordenamos estas parejas den orden descendiente con la función sort
eig_pairs.sort(key=lambda x: x[0], reverse=True)
# Visualizamos la lista de autovalores en orden desdenciente
print('Autovalores en orden descendiente:')
for i in eig_pairs:
   print(i[0])
Autovalores en orden descendiente:
4.912245750429123
3.0201922150701974
2.5502945378034636
1.969536169238358
1.7398580222523303
1.2546216086426745
1.1270109561812742
1.0936117108648045
0.9987229604633341
0.9108858284347017
0.8510344617635391
0.7449555053936743
0.7331995594865258
0.6455660670288373
0.5869022551758594
0.5123039373932055
0.5009543384323201
0.48570335600248954
0.4115936400921066
0.3493964105869995
0.3100625396577722
0.23473645162199175
0.07919950582824664
0.05938023436048195
0.031314844291713974
0.000752221223259712
```


Paso 5: Seleccionar los autovectores correspondientes a las componentes principales y graficar

```
# A partir de los autovalores, calculamos la varianza explicada
tot = sum(eig_vals)
var_exp = [(i / tot)*100 for i in sorted(eig_vals, reverse=True)]
cum_var_exp = np.cumsum(var_exp)

tamanio = len(columns_X)

# Representamos en un diagrama de barras la varianza explicada por cada autovalor, y la acumulada
with plt.style.context('seaborn-pastel'):
    plt.bar(np.arange(0,tamanio), var_exp, alpha=0.5, align='center', label='Varianza individual explicada', color='g')
    plt.ylabel('Ratio de Varianza Explicada')
    plt.xlabel('Componentes Principales')
    plt.legend(loc='best')
    plt.tight_layout()
```

En la siguiente gráfica se evidencia que la mayor parte de la varianza se encuentra correspondida en la primera componente



Paso 6: Proyectar en un espacio de dimensionalidad de 2D

```
plt.rcParams["figure.figsize"]=12,12


X_values_1 = []
Y_values_0 = []

Y_values_0 = []

for i in range(len(Y)):
    if(y.iloc[i]["isInTop100"]==1):
        X_values_1.append(Y[i][0])
        Y_values_1.append(Y[i][1])
    else:
        X_values_0.append(Y[i][0])
        Y_values_0.append(Y[i][1])

plt.scatter(X_values_1,Y_values_1,color="r",label="esta en el top 100")
plt.scatter(X_values_0,Y_values_0,color="b",label="NO esta en el top 100")
plt.xlabel('Componente Principal 1')
plt.ylabel('Componente Principal 2')
plt.legend(loc="lower right")
```

Obteniendo la siguiente representación de valores:



Donde se visualiza que con los valores de entrada es viable realizar una segmentación de los mismos con un posible predictor de empresas.

PUNTO 2.3

A continuación se realiza una regresión lineal mediante el método de "Least squares", el cual permitirá indicar según los valores de entrada de una empresa si esta puede entrar en el top 100 de empresas financiadas en colombia, en una escala de valores entre y no limitados a 0 y 1.

Para hacer la regresión lineal se utiliza R con el siguiente algoritmo:

```
file = "
    ..\\MMA_cursoMetodosAnalisisDatos
    \\Guillermo De Mendoza
    \\Mineria de datos - semestre 4
    \\Tarea4\\Plantilla.txt"
datos<-read.table(file, header=T, row.names=1)
rec = glm(isInTop100~.,family="binomial", data=datos)
rec</pre>
```

Desde la consola imprimimos los coeficientes:

```
> rec
Call: glm(formula = isInTop100 ~ ., family = "binomial", data = datos)
Coefficients:
                            (Intercept)
                                            minEstimatedRevenueRange
                             -8.318e+15
                                                          -1.065e+07
                       NumberofArticles
                                           maxEstimatedRevenueRange
                             1.035e+13
                                                           1.520e+06
                       NumberofFounders
                                                  minNumberEmployees
                             7.974e+13
                                                           1.269e+11
                  NumberofFundingRounds
                                                  maxNumberEmployees
                              4.432e+13
                                                          -9.499e+10
       LastFundingAmountCurrency.inUSD.
                                             isCompanyTypeForProfit
                              1.814e+07
                                                           2.235e+15
LastEquityFundingAmountCurrency.inUSD.
                                                    isCompanyPrivate
                                                           3.121e+15
                             -2.272e+07
TotalEquityFundingAmountCurrency.inUSD.
                                                          hasWebsite
                             1.612e+07
                                                           1.726e+15
     TotalFundingAmountCurrency.inUSD.
                                                          hasTwitter
                             -1.523e+07
                                                          -2.841e+14
                  NumberofLeadInvestors
                                                         hasFacebook
                             1.950e+14
                                                           1.535e+14
                      NumberofInvestors
                                                         hasLinkedIn
                                                          -8.461e+13
                             5.363e+13
                         NumberofEvents
                                                     hasContactEmail
                             5.336e+13
                                                           2.420e+14
                   CBRank.Organization.
                                                      hasPhoneNumber
                                                           1.643e+13
                             -7.560e+12
              BuiltWith.ActiveTechCount
                                                         isOperating
                              6.765e+12
                                                           3.395e+14
            G2Stack.TotalProductsActive
                             -2.587e+12
```

R Console

```
Degrees of Freedom: 228 Total (i.e. Null); 202 Residual
        Null Deviance:
                           166.1
        Residual Deviance: 1514
                                      AIC: 1568
Detalles:
 > summary(rec)
 Call:
 glm(formula = isInTop100 ~ ., family = "binomial", data = datos)
 Deviance Residuals:
                          3Q
   Min
         1Q Median
                                  Max
          0.00 0.00 0.00
  -8.49
                                  8.49
 Coefficients:
                                         Estimate Std. Error
                                                              z value
 (Intercept)
                                        -8.318e+15 6.958e+07 -119534933
                                        1.035e+13 1.377e+06
 NumberofArticles
                                                               7515182
                                        7.974e+13 4.004e+06
                                                              19917156
 NumberofFounders
                                        4.432e+13 3.869e+06
 NumberofFundingRounds
                                                               11453253
 LastFundingAmountCurrency.inUSD.
                                        1.814e+07 5.609e-01
                                                               32336220
 LastEquityFundingAmountCurrency.inUSD. -2.272e+07 5.783e-01 -39282565
 TotalEquityFundingAmountCurrency.inUSD. 1.612e+07 5.652e-01 28516804
 TotalFundingAmountCurrency.inUSD.
                                       -1.523e+07 5.562e-01 -27372977
NumberofLeadInvestors
                                        1.950e+14 7.681e+06
                                                             25382912
NumberofInvestors
                                        5.363e+13 1.829e+06
                                                             29327240
 NumberofEvents
                                        5.336e+13 6.515e+06
 CBRank.Organization.
                                       -7.560e+12 6.425e+04 -117662957
                                        6.765e+12 2.693e+05
                                                             25120818
 BuiltWith.ActiveTechCount
 G2Stack.TotalProductsActive
                                       -2.587e+12 6.668e+05
                                                               -3879473
                                       -1.065e+07 1.750e-01 -60848875
 minEstimatedRevenueRange
                                        1.520e+06 1.946e-02
                                                              78128585
maxEstimatedRevenueRange
                                        1.269e+11 9.235e+03
                                                              13745469
minNumberEmployees
                                       -9.499e+10 1.525e+03 -62296785
 maxNumberEmployees
 isCompanyTypeForProfit
                                        2.235e+15 4.142e+07
                                                               53945310
 isCompanyPrivate
                                        3.121e+15 3.742e+07
                                                             83409238
 hasWebsite
                                        1.726e+15 3.427e+07
                                                              50349045
                                       -2.841e+14 1.078e+07 -26357519
 hasTwitter
hasFacebook
                                        1.535e+14 1.230e+07
                                                             12482453
```

-8.461e+13 1.196e+07

2.420e+14 1.390e+07

1.643e+13 1.086e+07

3.395e+14 2.378e+07

-7071993

17416297

1513523

14279982

Analisis de variables en la regresión:

hasLinkedIn

isOperating

hasContactEmail

hasPhoneNumber

```
<2e-16 ***
(Intercept)
                                          <2e-16 ***
NumberofArticles
NumberofFounders
                                          <2e-16 ***
                                         <2e-16 ***
NumberofFundingRounds
                                         <2e-16 ***
LastFundingAmountCurrency.inUSD.
LastEquityFundingAmountCurrency.inUSD.
                                        <2e-16 ***
TotalEquityFundingAmountCurrency.inUSD.
                                         <2e-16 ***
TotalFundingAmountCurrency.inUSD.
                                          <2e-16 ***
                                          <2e-16 ***
NumberofLeadInvestors
                                          <2e-16 ***
NumberofInvestors
                                          <2e-16 ***
NumberofEvents
                                          <2e-16 ***
CBRank.Organization.
                                          <2e-16 ***
BuiltWith.ActiveTechCount
G2Stack.TotalProductsActive
                                          <2e-16 ***
minEstimatedRevenueRange
                                          <2e-16 ***
                                          <2e-16 ***
maxEstimatedRevenueRange
                                          <2e-16 ***
minNumberEmployees
maxNumberEmployees
                                          <2e-16 ***
isCompanyTypeForProfit
                                          <2e-16 ***
                                          <2e-16 ***
isCompanyPrivate
hasWebsite
                                          <2e-16 ***
                                          <2e-16 ***
hasTwitter
                                          <2e-16 ***
hasFacebook
hasLinkedIn
                                          <2e-16 ***
hasContactEmail
                                          <2e-16 ***
                                          <2e-16 ***
hasPhoneNumber
                                          <2e-16 ***
isOperating
```

Con lo cual concluimos que no se debe descartar ninguna de las variables de entrada en la regresión

```
Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 '' 1

(Dispersion parameter for binomial family taken to be 1)

Null deviance: 166.13 on 228 degrees of freedom
Residual deviance: 1513.83 on 202 degrees of freedom
AIC: 1567.8

Number of Fisher Scoring iterations: 18
```